



1η Προγραμματιστική Εργασία

-

Αναζήτηση διανυσμάτων στη C/C++

Ονοματεπώνυμο: Παπαθανασίου Ελένη

A.M.: 1115202200135

Ονοματεπώνυμο: Τόντου Αλτάνη-Δάφνη

A.M.: 1115202200288

Περίληψη

Η παρούσα μελέτη πραγματοποιεί συγκριτική ανάλυση τεσσάρων αλγορίθμων προσεγγιστικής αναζήτησης πλησιέστερων γειτόνων: LSH, Hypercube, IVFFlat και IVFPQ. Η αξιολόγηση πραγματοποιήθηκε στα datasets MNIST και SIFT.

1 Εισαγωγή

Στην εργασία αυτή υλοποιήθηκαν και αξιολογήθηκαν οι ακόλουθοι αλγόριθμοι:

- LSH (Locality Sensitive Hashing)
- Τυχαία Προβολή σε Υπερκύβο (Hypercube)
- IVFFlat (Inverted File Flat)
- IVFPQ (Inverted File Product Quantization)

2 Πειραματική Διαδικασία

2.1 Περιγραφή Πειραμάτων

Πραγματοποιήθηκαν πειράματα για:

- Αποτελέσματα και πίνακες για τα datasets MNIST και SIFT (LSH, Hypercube, IVFFlat, IVFPQ).
- Διαγράμματα μετρικών για κάθε αλγόριθμο (Recall@N, QPS, Avg AF, Aprox Time).
- Διαγράμματα σύγκρισης μετρικών για SIFT και MNIST.
- Σύγκριση μεταξύ αλγορίθμων.
- Συμπεράσματα και trade-off ανάλυση.
- Σύγκριση μεταξύ datasets.
- Τελικά Συμπεράσματα.

2.2 Μετρικές Αξιολόγησης

- **Recall@N**: Ποσοστό επιτυχούς ανάκτησης πλησιέστερων γειτόνων
- **QPS**: Αναζητήσεις ανά δευτερόλεπτο
- **Avg AF**: Μέσο κλάσμα προσέγγισης
- **Χρόνοι αναζήτησης**: Προσεγγιστικός vs Ακριβής

3 Αποτελέσματα Πειραμάτων

3.1 Αποτελέσματα και πίνακες για τα datasets

Algorithm	Dataset	Recall@N	QPS	Avg AF	Avg Approx Time (s)
Hypercube	SIFT	0.055	760.493	1.236	1.212
IVFFlat	SIFT	0.893	681.626	0.06	0.0
IVFPQ	SIFT	0.711	190.593	2.722	0.005
LSH	SIFT	0.084	678.479	1.17	1.877


Σχήμα 1: Detailed Summary SIFT

1	Algorithm	Dataset	Recall@N	QPS	Avg AF	Avg Approx Time (s)	Avg Exact Time (s)
2	Hypercube	MNIST	0.002	2.43	1.652	0.001	0.424
3	IVFFlat	MNIST	0.983	1.907	0.51	0.029	0.435
4	IVFPQ	MNIST	0.475	1.092	2.458	0.022	0.988
5	LSH	MNIST	0.03	3.115	1.537	0.002	0.32


Σχήμα 2: Detailed Summary MNIST

3.2 Διαγράμματα


- Τελικές Μετρικές για κάθε Αλγόριθμο




Σχήμα 3: Recall ανά Αλγόριθμο



Σχήμα 4: Aprox Time ανά Αλγόριθμο




Σχήμα 5: AF ανά Αλγόριθμο




Σχήμα 6: QPS ανά Αλγόριθμο


- Συγκρίσεις Μετρικών (SIFT)




Σχήμα 1: QPS vs Recall@N




Σχήμα 2: Recall@N vs Avg Approx Time (s) ανά αλγόριθμο




Σχήμα 3: Recall@N vs Avg AF ανά αλγόριθμο




Σχήμα 4: QPS vs Avg Approx Time (s) ανά αλγόριθμο



Σχήμα 5: QPS vs Avg AF ανά αλγόριθμο




Σχήμα 6: Avg Exact Time (s) vs Avg Approx Time (s) ανά αλγόριθμο




Σχήμα 7: Avg AF vs Avg Approx Time (s) ανά αλγόριθμο


- Συγκρίσεις Μετρικών (MNIST)




Σχήμα 1: QPS vs Recall@N




Σχήμα 2: Recall@N vs Avg Approx Time (s) ανά αλγόριθμο




Σχήμα 3: Recall@N vs Avg AF ανά αλγόριθμο




Σχήμα 4: QPS vs Avg Approx Time (s) ανά αλγόριθμο



Σχήμα 5: QPS vs Avg AF ανά αλγόριθμο



Σχήμα 6: Avg Exact Time (s) vs Avg Approx Time (s) ανά αλγόριθμο



Σχήμα 7: Avg AF vs Avg Approx Time (s) ανά αλγόριθμο

4 Συγκρίσεις και Συμπεράσματα

4.1 Σύγκριση Αλγορίθμων

4.1.1 Ακρίβεια (Recall@N)

- **SIFT Dataset:**
 - Καλύτερος: IVFFlat (Recall@N ≈ 0.893)
 - Δεύτερος: IVFPQ (Recall@N ≈ 0.711)
 - Χαμηλότεροι: LSH & Hypercube (Recall@N ≈ 0.084 & 0.055)
- **MNIST Dataset:**
 - Καλύτερος: IVFFlat (Recall@N ≈ 0.983 - σχεδόν τέλειος)
 - Δεύτερος: IVFPQ (Recall@N ≈ 0.475)
 - Χαμηλότεροι: LSH & Hypercube (Recall@N ≈ 0.030 & 0.002)

Συμπέρασμα: Οι αλγόριθμοι βασισμένοι σε συσταδοποίηση (IVF) είναι πολύ πιο ακριβείς.

4.1.2 Ταχύτητα (QPS)

- **SIFT Dataset:**
 - Πιο γρήγορος: Hypercube (QPS ≈ 760.493)
 - Δεύτερος: IVFFlat (QPS ≈ 681.626)
 - Τρίτος: LSH (QPS ≈ 678.479)
 - Πιο αργός: IVFPQ (QPS ≈ 190.593)
- **MNIST Dataset:**
 - Πιο γρήγορος: LSH (QPS ≈ 3.115)
 - Δεύτερος: Hypercube (QPS ≈ 2.43)
 - Πιο αργοί: IVFFlat & IVFPQ (QPS ≈ 1.9 & 1.09)

Συμπέρασμα: Το SIFT τρέχει πολύ πιο γρήγορα (καλύτερα βελτιστοποιημένο), ενώ το MNIST είναι γενικά πιο αργό.

4.1.3 Ποιότητα Προσέγγισης (Avg AF)

- **SIFT Dataset:**
 - Καλύτερος: IVFFlat (AF ≈ 0.06 - εξαιρετικός)
 - Χειρότερος: IVFPQ (AF ≈ 2.722 - χαμηλή ποιότητα)
 - LSH & Hypercube: AF ≈ 1.17 & **1.236** (ικανοποιητικά)
- **MNIST Dataset:**
 - Καλύτερος: IVFFlat (AF ≈ 0.51)
 - Χειρότερος: IVFPQ (AF ≈ 2.458)
 - LSH & Hypercube: AF ≈ 1.537 & **1.652**

Συμπέρασμα: Ο IVFFlat δίνει τις καλύτερες προσεγγίσεις, ενώ ο IVFPQ έχει προβλήματα ακρίβειας.

4.1.4 Χρόνοι Αναζήτησης

- **SIFT Dataset:**
 - **Πιο γρήγορος:** IVFFlat ($\approx 0.0\varsigma$ - βελτιστοποιημένος)
 - **Αργότεροι:** Hypercube & LSH ($\approx 1.2\varsigma$ & 1.87ς)
 - **IVFPQ:** $\approx 0.005\varsigma$ (ικανοποιητικός)

Συμπέρασμα: Ο IVFFlat είναι ασταθείς σε χρόνους αναζήτησης.

4.2 Trade-off Ανάλυση

4.2.1 Ακρίβεια vs Ταχύτητα (Σχήμα 1)

- **IVFFlat:** Υψηλή ακρίβεια + υψηλή ταχύτητα = **Καλύτερος overall**
- **Hypercube:** Χαμηλή ακρίβεια + υψηλή ταχύτητα = Καλός για γρήγορες απαντήσεις
- **IVFPQ:** Μέτρια ακρίβεια + χαμηλή ταχύτητα = **Δεν συνιστάται**
- **LSH:** Χαμηλή ακρίβεια + μέτρια ταχύτητα = Περιορισμένη χρήση

4.2.2 Ακρίβεια vs Χρόνος (Σχήμα 2)

- **IVFFlat:** Υψηλή ακρίβεια + ελάχιστος χρόνος = **Βέλτιστη επιλογή**
- **Hypercube/LSH:** Χαμηλή ακρίβεια + υψηλός χρόνος = **Αποτυχία**

4.3 Σύγκριση Datasets

4.3.1 MNIST vs SIFT

- **MNIST:** Γενικά καλύτερη ακρίβεια αλλά χειρότερη ταχύτητα
- **SIFT:** Καλύτερη ταχύτητα, μέτρια ακρίβεια
- **IVFFlat:** Εξαιρετικός και στα δύο datasets
- **Hypercube:** Καλύτερος στο SIFT, χειρότερος στο MNIST

4.4 Τελικά Συμπεράσματα

- **Για Υψηλή Ακρίβεια:** **IVFFlat** - Σχεδόν τέλειος recall (0.98 στο MNIST, 0.89 στο SIFT) με καλή ταχύτητα
- **Για Μέγιστη Ταχύτητα:** **Hypercube** - 760 QPS στο SIFT, αλλά με θυσία ακρίβειας
- **Για Ισορροπημένη Απόδοση:** **LSH** - Ικανοποιητική ταχύτητα και AF, αλλά χαμηλή ακρίβεια
- **Δεν Συνιστάται:** **IVFPQ** - Χαμηλή ταχύτητα + χαμηλή ακρίβεια + υψηλό AF
- **Βέλτιστη Επιλογή Overall:** **IVFFlat** - Κερδίζει σε όλες τις κατηγορίες εκτός από απόλυτη ταχύτητα

4.5 Παρατηρήσεις

1. Το SIFT φαίνεται καλύτερα βελτιστοποιημένο (πολύ υψηλότερα QPS)
2. Οι παράμετροι default ίσως δεν είναι βέλτιστες για LSH & Hypercube
3. Χρειάζεται brute force σύγκριση για απόλυτα αξιόπιστα συμπεράσματα